
阶段 1: 环境导入与数据加载

🔍 对应代码：前两个包含 `import pandas as pd...` 和 `pd.read_csv(...)` 的代码块。

- 代码在干嘛：第一块代码在召唤各种“工具人”：pandas 负责处理表格，numpy 负责高阶数学计算，matplotlib/seaborn/plotly 则是画图三大金刚，scikit-learn 是机器学习的武器库。第二块代码把 `water_potability.csv` 文件真正读取到了电脑内存里，并命名为 `data`。
- 学术表达：导入核心依赖库，并完成本地数据集的实例化加载，为后续探索性数据分析（EDA）奠定基础。

阶段 2: 基础数据探索

🔍 对应代码：包含 `data.head()`、`data.describe()`、`data.info()` 和 `data.shape` 的代码块。

- 代码在干嘛：
 - `.head()`：抽出表格的前 5 行看一眼长啥样。
 - `.describe()`：极其强大，一键算出了每一列水质指标的平均值、最大值、最小值和标准差。
 - `.info()` 和 `.shape`：这张表一共 3276 行、10 列，以及每一列是什么数据类型（比如 `float64` 代表带小数点的数字）。
- 学术表达：提取数据集的描述性统计特征，验证数据维度，并排查潜在的数据类型异常。

阶段 3: 缺失值分析

🔍 对应代码：包含 `data.isnull().mean().plot.bar...` 的画图代码。

- 代码在干嘛：`.isnull()` 会去扫描表里的每一个格子，如果是空的 (NaN) 就标出来，然后算出每一列空缺的百分比，并画成一个直观的柱状图。
- 学术表达：量化评估特征空间的缺失率。识别出 `ph`、`Sulfate` (硫酸盐) 和 `Trihalomethanes` (三卤甲烷) 存在显著的缺失情况，提示后续必须介入缺失值插补机制。

阶段 4: 类别不平衡检测

🔍 对应代码：包含 `px.pie(...)` 和 `px.bar(...)` 画饼图/柱状图的代码。

- 代码在干嘛：专门针对最后一列 `Potability` (是否可饮用: 0 为否, 1 为是) 去数人头。发现 0 比 1 多出不少。
- 学术表达：对目标标签进行频数统计。证实了分类变量存在轻度倾斜 (Class Imbalance)，提示模型可能会在训练中产生多数类偏好。

阶段 5: 特征分布与相关性

🔍 对应代码：画出一排排密集的山峰图 `sns.kdeplot(...)`，以及花花绿绿的热力图 `sns.heatmap(...)`

。

- 代码在干嘛：
 - 山峰图 (KDE): 看每一个水质指标的数据是不是主要集中在中间(正态分布)。
 - 热力图 (Heatmap): 计算指标和指标之间有没有“互相勾结”(比如硬度高了, pH会不会也跟着高)。颜色越深/越浅说明关系越铁, 但这批数据大家互相都不怎么搭理对方(数值都很接近0)。
- 学术表达: 通过核密度估计(KDE)验证了多数理化指标近似服从高斯分布。皮尔逊相关性矩阵(Pearson Correlation)表明各特征间相互独立, 不存在多重共线性(Multicollinearity)。

阶段 6: 缺失值填补

🔍 对应代码: 包含 `data = data.fillna(data.mean())` 的代码块。

- 代码在干嘛: 这就是我们最骄傲的那个 Bug 修复点! 它把刚才在阶段 3 找出来的那些“窟窿”, 极其温柔地用那一列的“平均值(mean)”给填补了进去, 防止后面的模型因为读到空数据而崩溃。
- 学术表达: 采用均值插补(Mean Imputation)策略修复了数据缺失, 最大限度保留了样本的统计学特征与整体方差。

阶段 7: 数据重采样

🔍 对应代码: 包含 `from sklearn.utils import resample` 和合并表格的代码。

- 代码在干嘛: 针对阶段 4 发现的“可饮用水(1)”太少的问题, 这段代码直接用了“影分身之术”(过采样 Oversampling), 随机复制“1”的数据, 直到它和“0”的数量一模一样多(都是1998个), 强行把水端平。
- 学术表达: 应用随机过采样(Random Oversampling)技术强制扩充少数类样本, 实现了目标变量的 1:1 绝对均衡, 消除了算法先验偏差。

阶段 8: 划分数据集与标准化

🔍 对应代码: 包含 `train_test_split(...)` 和 `StandardScaler()` 的代码块。

- 代码在干嘛：
 - 划分数据集: 把所有数据劈成两半。一大部分当做“练习题”交给模型学习(Train), 留下一小部分当做“期末考试题”用来测试模型到底学得怎么样(Test)。
 - 标准化 (StandardScaler): 把所有的数据等比例缩放到同一个量级。因为 Solids(溶解物)动不动就好几万, 而 pH 只有 1 到 14, 如果不缩放, 模型会误以为 Solids 数字大就更重要。
- 学术表达: 构建 Train-Test 切分以保障评估的泛化能力。引入 Standard Scaler 消除不同理化指标间的量纲差异, 加速梯度下降并防止大尺度特征主导目标函数。

阶段 9: 模型训练与评估

🔍 对应代码: 后面所有包含 `LogisticRegression()`, `DecisionTreeClassifier()`,

RandomForestClassifier() 以及各种混淆矩阵(四个彩色方块)的代码。

- 代码在干嘛：这就是真正的机器学习！代码依次把清洗好的数据喂给不同的算法大脑。算出来的 Accuracy(准确率)就是它们的期末考试分数。彩色方块矩阵(混淆矩阵)则详细指出了模型到底是把“好水误判成了毒水”，还是“毒水误判成了好水”。
 - 学术表达：横向对比了线性基线模型与多种非线性分类器。通过交叉验证与混淆矩阵解析，证实了集成学习(如随机森林)在处理高维非线性水质特征时的高效性与卓越性能。
-